

UTILIZAÇÃO DE HEURÍSTICAS PARA SOLUÇÃO DE UM PROBLEMA DE PLANEJAMENTO FLORESTAL

Gabriel R. da Silva¹, Gustavo H. A. Rocha¹

¹Instituto de Federal do Norte de Minas Gerais - *Campus* Montes Claros (IFNMG)
CEP 39404-058 – Montes Claros – MG – Brasil

{grs17, ghar1}@aluno.ifnmg.edu.br

Abstract. *This work presents a heuristic approach to solving a forest planning problem, focusing on maximizing the Net Present Value (NPV) while adhering to production and integrity constraints. A total of 120 management units and 81 prescriptions were used, exploring neighborhoods generated by purely random, localized, and systematic methods. Local Search heuristics and Simulated Annealing (SA) were applied to explore the neighborhood with different experimental configurations. The results demonstrated the capability of Simulated Annealing in optimizing this problem. The Genetic Algorithm achieved results in a similar time frame to the other methods but did not outperform SA and Local Search.*

Resumo. *Este trabalho apresenta uma abordagem heurística para solução de um problema de planejamento florestal, focado na maximização do Valor Presente Líquido (VPL) respeitando restrições de produção e integridade. Foram utilizadas 120 unidades de manejo e 81 prescrições, explorando vizinhanças geradas por métodos puramente aleatórios, localizados e sistemáticos. Heurísticas de Busca Local e Simulated Annealing (SA) foram usadas explorando a vizinhança com diferentes configurações dos experimentos e os resultados mostraram a capacidade do Simulated Annealing na otimização deste problema, o Algoritmo Genético obteve resultados em tempo semelhante aos demais, porém não obteve melhores resultados em comparação com o SA e à Busca Local.*

1. Introdução

As meta-heurísticas, assim chamadas as heurísticas estocásticas, são ferramentas amplamente utilizadas e exploradas no meio científico, nos últimos anos sua aplicação também vem sendo observada no meio florestal, para solução de problemas de otimização e gerenciamento de recursos (BARRAL, 2022).

De forma geral, a tarefa de realizar um planejamento florestal consiste em determinar o plantio e a colheita de unidades de manejo em determinados períodos, com objetivo de atender demandas mínimas e máximas de produção na tentativa de maximizar os lucros, além das demais restrições impostas (WERNEBURG, 2015).

Entretanto, o gerenciamento de recursos e seleção de uma estratégia de planejamento pode ser uma tarefa complexa que envolve um grande número de variáveis de decisões, podendo ser extremamente custosas computacionalmente ou até mesmo inviáveis. Nesses casos, as heurísticas e meta-heurísticas como técnicas de otimização são caminhos viáveis na obtenção de respostas satisfatórias (BARRAL, 2022).

2. Materiais e Métodos

2.1. Definição do Problema

Como descrito em JUNIOR et al. (2012), a Figura 1 representa uma floresta que é dividida em várias unidades de produção, que são áreas sem descontinuidade e com características homogêneas como: mesma espécie, semelhança de material genético, mesma idade das árvores, altitude, etc. Para cada unidade de produção, existe um conjunto de alternativas de manejo, que representam um sequência de decisões que ocorrem ao longo de um horizonte de planejamento. JUNIOR et al. (2012) ainda explica que as tomadas de decisão para cada unidade de produção pode representar por exemplo épocas de cortes, plantios, intensidades de desbastes, tecnologias utilizadas entre outras.

Para este trabalho, foi utilizada a base de dados elaborada por JUNIOR et al. (2021), na qual ele define uma floresta de eucalipto com idades variando entre 1 e 6 anos e área total igual a 4.210 hectares, essa floresta foi seccionada em 120 unidades de produção (talhões) e geradas 81 diferentes alternativas de manejo (prescrições) para um horizonte de planejamento de 16 anos. A colheita é realizada apenas em talhões com idades entre 5 e 7 anos com plantio imediato após a colheita.

A complexidade desse tipo de problema vem da grande quantidade de possibilidades de tomada de decisão possíveis, uma vez que, dado um grande número de unidades de produção, devemos estipular a melhor alternativa de manejo para cada uma com a finalidade de maximizar o lucro.




Figura 1. Floresta dividida em unidades de produção

2.2. Modelagem do Problema

A base de dados utilizada é disposta em 9721 linhas e 20 colunas, sendo as três primeiras colunas o identificador do talhão, a idade e a prescrição que pode ser atribuída ao talhão respectivamente. As demais colunas representam o ano no horizonte de planejamento e o volume colhido de madeira dado um talhão e sua prescrição associada, com a última coluna sendo o Valor Presente Líquido (VPL) obtido, como mostrado na Figura 2.

talhão	idade	prescrição	1	...	16	VPL
1	1	1	0	...	0	14703
1	1	2	0	...	0	14703
...	...	...	...	...	...	...
120	6	80	8960	...	8960	442508
120	6	81	8960	...	8960	442508

Figura 2. Representação da base de dados com 120 talhões e 81 prescrições com horizonte de planeamento em 16 anos

Para este problema de planeamento, pretende-se encontrar um conjunto de prescrições que maximize o VPL ao longo do horizonte de planeamento. Há de se tomar precaução quanto a escolha das prescrições, pois para cada talhão é válido apenas uma única prescrição inteira para cada talhão além de haver uma penalidade no VPL para produções anuais de madeira abaixo de $140000m^3$ ou acima de $160000m^3$. O modelo matemático foi proposto por JOHNSON and SCHEURMANN (1977) e é apresentado a seguir pela equação 1.

$$\text{Max } VPL = \sum_{i=1}^M \sum_{j=1}^P VPL_{ij} \cdot X_{ij} \quad (1)$$

$$\sum_{j=1}^P X_{ij} = 1 \quad \forall i \in \{1, \dots, M\} \quad (2)$$

$$\sum_{i=1}^M \sum_{j=1}^P V_{ijk} \cdot X_{ij} \geq D_{\min k} \quad \forall k \in \{1, 2, \dots, 16\} \quad (3)$$

$$\sum_{i=1}^M \sum_{j=1}^P V_{ijk} \cdot X_{ij} \leq D_{\max k} \quad \forall k \in \{1, 2, \dots, 16\} \quad (4)$$

$$X_{ij} \in \{0, 1\} \quad (5)$$

O VPL máximo é calculado pela soma do VPL do talhão i dado a prescrição j multiplicado pela variável binária X_{ij} , que garante que um talhão receberá uma única prescrição inteira, representados pelas Equações 2 e 5. O valor M é o número de talhões totais, P a quantidade de prescrições e k o ano no horizonte de planeamento. Os volumes anuais de madeira faltante ou excedente são apresentados nas equações 3 e 4, com V_{ijk} sendo o volume colhido no talhão i com a prescrição j no ano k com a variável binária de decisão X_{ij} . Os limites de volume mínimo e máximo $D_{\min k}$ e $D_{\max k}$ são respectivamente $140000m^3$ e $160000m^3$.

A penalização aplicada para cada unidade de volume faltante ou excedente no ano foi de R\$500,00 (quinhentos reais) que é subtraído da Equação 1 e representado pela Equação 6:

$$\text{Max } VPL = \sum_{i=1}^M \sum_{j=1}^P (VPL_{ij} \cdot X_{ij}) - P_e \sum_{k=1}^T dk \quad (6)$$

Em que: P_e é o valor da penalidade por volume fora dos limites e dk o volume absoluto desviado, com k sendo uma ano do total de T anos do horizonte de planejamento.

2.3. Revisão da Literatura

Diversos trabalhos da literatura buscam uma melhora no resultado otimizando a seleção das prescrições por meio da aplicação de meta-heurísticas. RODRIGUES et al. (2003) busca solucionar problemas de planejamento florestal utilizando busca tabu em instâncias de diferentes tamanhos, com números de talhões variando de 10 a 40 e número de prescrições entre 93 e 423. Em seu trabalho, sua solução inicial é gerada aleatoriamente. Na solução deste problema, também foi usando algoritmo genético por RODRIGUES et al. (2004), a população inicial também foi gerada aleatoriamente. JUNIOR et al. (2021) apresenta o uso da programação linear na geração de uma solução inicial com a mesma base de dados, as meta-heurísticas utilizadas em seu trabalho foram *clonal selection algorithm* (CSA), *genetic algorithm* (GA), *simulated annealing* (SA) e *variable neighborhood search* (VNS) e seus resultados mostram que a performance dos algoritmos CSA, AG e VNS foram melhorados utilizando o arredondamento encontrado pela programação linear como solução inicial.

3. Metodologia Proposta

3.1. Solução Inicial

Para este trabalho, propusemos a utilização de uma heurística construtiva por busca aleatória através dos candidatos de uma lista com um limiar μ e $\alpha \in [0, 1]$ pela Equação 7, comparado com o VPL de cada prescrição e executando cada valor de α por 10 segundos. Para cada um dos talhões, selecionamos apenas as prescrições com VPL maior ou igual que μ para a lista de candidatos e aleatoriamente selecionamos uma prescrição de cada lista para formular a solução inicial. Abordagens estritamente gulosas possuem altas chances de ficarem presas em ótimos locais por apenas escolherem o próximo item mais promissor sem se importar com as consequências.(ZÄPFEL et al., 2014).

$$\mu = VPL_{max} - \alpha \cdot (VPL_{max} - VPL_{min}) \quad (7)$$

Os experimentos realizados foram testados com valores de $\alpha = 0, 0.5$ e 1 , sendo que $\alpha = 0$ a lista de candidatos será composta apenas pelo maior VPL e a solução será estritamente gulosa, $\alpha = 1$ uma solução completamente aleatória e $\alpha = 0.5$ uma lista de candidatos intermediária.

Utilizando essa instância como referência, o limite superior para o problema relaxado foi de R\$36 334 070 e o valor de referência usado no cálculo de desvio foi de

R\$32 170 883, ambos encontrados em (JUNIOR et al., 2021), o qual utilizou a solução encontrada pelo algoritmo *branch-and-bound* como VPL de referência. Os resultados encontrados estão presentes na Tabela 1, sendo a Eficiência definida pela equação 8:

$$Ef = \frac{VPL_{max}}{VPL_{ref}} \quad (8)$$

Alpha (α)	VPL máximo (R\$)	Desvio (R\$)	Eficiência
0.0	-813.202.930	-845.373.813	-25.27
0.5	-476.071.013	-508.241.896	-14.79
1.0	-28.946.365	-61.117.248	-0.89

Tabela 1. Resultados do VPL máximo e comparação do desvio e eficiência com resultado referência.

Com base na análise dos resultados, foram utilizadas duas heurísticas, a "Busca Local" e a "Simulated Annealing" para otimizar a seleção ideal das prescrições a fim de maximizar o VPL total no horizonte de planejamento, utilizando o melhor resultado encontrado em α como solução inicial para geração das vizinhanças.

3.2. Vizinhanças

Com a solução inicial encontrada na heurística construtiva, a nova etapa do problema é a aplicação de diferentes heurísticas, então é preciso gerar vizinhanças para serem exploradas pela Busca Local e pelo *Simulated Annealing*.

Foram utilizadas três diferentes abordagens para geração de vizinhanças, as quais serão exploradas pelas heurísticas. A primeira abordagem é a "Vizinhança Puramente Aleatória" que sorteia um talhão entre os 120 possíveis, variando a prescrição deste talhão, resultando entre 13 e 29 diferentes soluções, como mostrado na Figura 3 (a).

A segunda abordagem é a "Vizinhança Localizada", Figura 3 (b), sendo mais direcionada que uma geração puramente aleatória. Neste caso é identificado o ano que possui o maior desvio volumétrico de produção de madeira do limite superior de $160000m^3$, resultando em uma maior penalidade. Devida à modelagem do problema, alguns talhões não podem ser colhidos em certos anos (e.g. Talhão de idade 1 e colheita no ano 1), filtramos apenas os talhões que possuem uma prescrição que realize uma colheita naquele pior ano e geramos os vizinhos com base na vizinhança puramente aleatória, na tentativa de direcionar esforços nos anos mais prejudiciais.

A terceira abordagem é a "Vizinhança Sistemática" onde são geradas 120 vizinhos, em que cada vizinho é uma cópia da solução atual, tendo como alteração apenas um único talhão com uma prescrição aleatória e mantendo os 119 talhões restantes inalterados, representado na Figura 3 (c).




Figura 3. Fluxograma das diferentes gerações das vizinhanças. (a) Vizinhança puramente aleatória. (b) Vizinhança localizada. (c) Vizinhança sistemática.

3.3. Busca Local

A primeira heurística utilizada foi a Busca Local, que percorre uma vizinhança sempre buscando um melhor vizinho através da função objetivo e atualizando a solução atual. É um algoritmo que recorrentemente encontra mínimos/máximos locais devido ao seu fator de intensidade, possuindo poucas técnicas para fugir desses valores. (ZÄPFEL et al., 2014)

Na exploração de vizinhanças, são utilizados dois métodos distintos: a primeira melhora e a melhor melhora. Durante a varredura de uma vizinhança, verifica-se se os vizinhos gerados proporcionam uma melhoria na solução atual. No método de primeira melhora, assim que ocorre a primeira troca por uma solução superior, a exploração dessa vizinhança é encerrada, e uma nova vizinhança é gerada. Esse mecanismo promove uma maior diversidade de vizinhanças exploradas, possibilitando a descoberta de soluções potencialmente melhores em diferentes regiões do espaço de busca. Na melhor melhora, toda a vizinhança gerada é analisada em busca do melhor vizinho, armazenando a melhor solução explorada, tendo este método um caráter de mais intensidade ao invés de diversidade.

Em ambos os casos, uma nova vizinhança é gerada com a nova solução melhorada, dando continuidade ao processo de busca. Caso uma vizinhança não possua um vizinho melhor que a solução atual, repetimos o processo de gerar uma nova vizinhança, fazendo com que a busca apenas seja encerrada ao atingir um certo número de cálculos da função objetivo.

3.4. Simulated Annealing

A segunda heurística utilizada foi a *Simulated Annealing*, inspirada na ideia de resfriamento de fluidos, este algoritmo utiliza o conceito de temperatura, que permite a troca de uma solução para explorar diferentes vizinhanças para escapar de máximos locais, em conjunto com uma taxa de resfriamento que permite que a temperatura decaia ao longo das iterações. Na exploração das vizinhanças através dos diferentes métodos, para soluções melhores que a atual é realizada uma troca garantida, atualizando a melhor solução atual, porém para soluções piores é gerada uma probabilidade de aceitação com base nas Equações 9 e 10, onde a diferença da melhor solução com a solução atual é comparada dada a temperatura atual. Um número n de iterações são realizadas antes de ocorrer um resfriamento na temperatura, permitindo uma maior exploração da vizinhança com a temperatura atual. (ZÄPFEL et al., 2014)

$$\Delta E = VPL_{melhor} - VPL_{atual} \quad (9)$$

$$P(\Delta E) = \exp\left(-\frac{\Delta E}{T}\right) \quad (10)$$

Para este trabalho, utilizamos como configuração de parâmetros uma temperatura inicial = 10^5 , taxa de resfriamento = 0,99% e número de iterações = 40.

3.5. Algoritmo Genético

O Algoritmo Genético (AG), pertence a um grupo chamado de Algoritmos Evolucionários, que imitam o processo de seleção, recombinação e substituição da população através da ideia de seleção natural dos seus indivíduos, fazendo que os indivíduos mais promissores gerem melhores soluções (HILLIER and LIEBERMAN, 2006). ZÄPFEL et al. (2014) aborda os principais componentes dos algoritmos genéticos e seu fluxo de execução, sendo representados na Figura 4.




Figura 4. Processamento de um Algoritmo Genético. Adaptado de (ZÄPFEL et al., 2014)

1. Inicialização

Para etapa de inicialização deste trabalho, foi utilizado a solução inicial gerada a partir da heurística construtiva com valor $\alpha = 1$. Para cada um dos 40 indivíduos da população inicial, realizamos um embaralhamento aleatório na solução inicial, desta forma, mantendo um viés de solução promissora além de um certo grau de variação entre os indivíduos.

2. Avaliação

A avaliação de cada indivíduo foi feita com base na Equação 6, em que o VPL de um indivíduo é calculado através das prescrições escolhidas e subtraído a penalidade do volume faltante e excedente.

3. Seleção

A partir de uma população, é necessário selecionar os pares que irão realizar a recombinação. Para tal tarefa, utilizamos um operador de torneio, em que 4 indivíduos são selecionados aleatoriamente e escolhido o de maior VPL para ser o primeiro pai. O segundo pai é obtido da mesma forma, porém removendo temporariamente o primeiro escolhido para evitar pais iguais.

4. Recombinação

Na etapa de recombinação, dado os pares de pais selecionados anteriormente, é realizado um cruzamento genético entre os indivíduos. Analogamente, selecionamos 1 ponto de cruzamento aleatório e realizamos a inversão das prescrições dos pais pré e pós ponto de cruzamento, gerando dois filhos $p1 \mid p2'$ e $p2 \mid p1'$. Sendo $p1$ e $p1'$ as prescrições da primeira e segunda parte até o ponto de cruzamento do primeiro pai e o mesmo para $p2$ e $p2'$ e a cada nova geração, são gerados 40 filhos.

5. Mutação

A mutação é um importante operador genético que atua amenizando uma convergência prematura dos indivíduos no decorrer das gerações ao realizar pequenas alterações no indivíduo dada uma probabilidade desta mutação ocorrer. Caso um indivíduo seja selecionado pela taxa de mutação – para este trabalho 1% –, realizamos uma troca entre duas prescrições aleatórias.

6. Substituição

Após a geração dos filhos, é necessário designar os indivíduos para a próxima geração. Nesta etapa, unimos a população atual com os novos filhos e selecionamos os 10 melhores indivíduos, preenchendo o restante da população com o método de torneio com 4 indivíduos. Uma nova geração será iniciada com a nova população substituída, repetindo todos os passos descritos na Figura 4 até que o critério de parada seja atingido.

4. Resultados e Discussão

Todos os experimentos foram executados com um determinado número máximo de cálculos de função objetivo, sendo esta função a equação 6 e encerrando a busca ao atingir tal número máximo. Também foi considerada a execução de todos os testes 15 vezes e utilizada a média nas comparações a fim de evitar vieses da escolha de uma boa semente geradora de números aleatórios, uma vez que as vizinhanças elaboradas, o *Simulated Annealing* e o Algoritmo Genético possuem um caráter aleatório. Todas as execuções foram submetidas a testes com 5000, 10000, 25000 e 50000 cálculos máximos da função objetivo e executadas em uma máquina com processador Ryzen 7 5700G e 16GB de memória RAM.

Na tabela 4, estão destacados os melhores resultados em termos de eficiência de cada algoritmo e sua vizinhança. É possível observar que ambos os algoritmos performaram relativamente bem quando comparados entre si, porém mantendo uma eficiência máxima de 95.8% com o *simulated annealing*, vizinhança aleatória e 50000 cálculos de função objetivo em relação ao valor de referência, além de possuir o menor tempo médio de execução dentre os melhores resultados destacados. Apenas a busca local com vizinhança sistemática e primeira-melhora e ambos os casos do *simulated annealing* obtiveram resultados superiores a R\$30.900.000. O Algoritmo Genético obteve a pior performance em todos os experimentos quando comparado aos outros dois algoritmos.

Meta heurística	Método	NumCálculos	Média (R\$)	Máximo (R\$)	Mínimo (R\$)	Eficiência	Tempo (s)
BL: Aleatória	mm	5000	30.070.178,20	30.232.238,00	29.833.519,00	0.935	65.5
		10000	30.228.779,27	30.424.461,00	29.951.679,00	0.940	128.7
		25000	30.368.317,20	30.530.503,00	30.062.992,00	0.944	324.9
		50000	30.391.865,20	30.621.658,00	30.062.992,00	0.945	641.0
	pm	5000	29.634.885,80	29.927.688,00	29.113.683,00	0.921	65.1
		10000	29.887.783,20	30.110.594,00	29.610.254,00	0.929	130.2
		25000	30.089.794,20	30.315.834,00	29.730.829,00	0.936	330.2
		50000	30.101.218,87	30.315.834,00	29.730.829,00	0.936	671.1
BL: Localizada	mm	5000	29.990.628,93	30.265.128,00	29.752.982,00	0.932	73.2
		10000	30.145.391,80	30.455.799,00	29.944.008,00	0.937	149.4
		25000	30.255.801,93	30.545.698,00	29.994.012,00	0.940	371.3
		50000	30.276.225,67	30.557.266,00	29.994.012,00	0.941	750.1
	pm	5000	29.643.598,07	30.041.631,00	28.866.800,00	0.921	77.7
		10000	29.939.598,67	30.315.065,00	29.716.920,00	0.931	153.8
		25000	30.168.123,00	30.460.816,00	29.822.508,00	0.938	748.0
		50000	30.218.531,53	30.480.524,00	29.822.508,00	0.939	748.0
BL: Sistemática	mm	5000	29.960.320,67	30.055.075,00	29.832.078,00	0.931	63.4
		10000	30.179.008,80	30.344.459,00	29.953.515,00	0.938	127.1
		25000	30.368.174,93	30.668.072,00	29.956.035,00	0.944	340.2
		50000	30.384.593,93	30.722.049,00	29.956.035,00	0.944	682.0
	pm	5000	30.271.585,27	30.448.589,00	30.145.331,00	0.941	69.2
		10000	30.492.485,13	30.678.558,00	30.315.255,00	0.948	133.5
		25000	30.666.938,07	30.905.872,00	30.497.649,00	0.953	339.1
		50000	30.691.932,53	30.905.872,00	30.497.649,00	0.954	675.5
SA: Aleatória	pm	5000	30.049.511,47	30.325.327,00	29.755.073,00	0.934	46.3
		10000	30.226.367,13	30.439.430,00	30.066.828,00	0.940	102.1
		25000	30.623.788,53	30.903.224,00	30.484.667,00	0.952	246.7
		50000	30.811.727,27	30.939.849,00	30.536.352,00	0.958	507.8
SA: Localizada	pm	5000	30.016.152,00	30.182.183,00	29.898.104,00	0.933	86.2
		10000	30.203.581,40	30.479.174,00	30.014.130,00	0.939	220.8
		25000	30.544.168,53	30.762.503,00	30.314.710,00	0.949	386.9
		50000	30.797.092,87	30.912.976,00	30.662.496,00	0.957	809.0
Algoritmo Genético	-	5000	6.554.814,00	11.529.932,00	-14.926.232,00	0.204	59.5
		10000	13.404.776,00	22.868.922,00	5.297.959,00	0.417	141.7
		25000	21.682.053,00	28.287.942,00	2.927.771,00	0.674	361.4
		50000	25.773.563,00	29.245.765,00	18.315.377,00	0.801	701.1

Tabela 2. Resultados obtidos para as heurísticas com as diferentes configurações de método e número de cálculos.

Ao observar graficamente a evolução do VPL médio para cada experimento ao decorrer do número máximo de cálculos da função objetivo na Figura 5, é possível observar uma aparente estabilização nos resultados utilizando a busca local a partir dos 25000 cálculos de função objetivo, enquanto o *simulated annealing* apresenta uma crescente evolução no VPL ainda nos 50000 cálculos máximos, mostrando uma potencial melhora quando possui mais processamento disponível para busca. Contudo, para execuções menores com até 25000 cálculos de função objetivo, a busca local com vizinhança sistemática e primeira melhora apresentou melhores resultados tanto na média quanto no VPL máximo apresentado na figura 6 em relação aos demais experimentos e a figura 7 mostra o VPL máximo do Algoritmo Genético para os pontos de parada definidos.




Figura 5. Comparação da evolução do VPL médio dos melhores experimentos para cada algoritmo e sua vizinhança.




Figura 6. Comparação da evolução do VPL máximo dos melhores experimentos para cada algoritmo e sua vizinhança.

A figura 8 mostra a distribuição dos resultados encontrados com os melhores métodos nas 15 execuções com 50000 cálculos de função objetivo. Os métodos de busca local com vizinhança aleatória e localizada tiveram resultados mais dispersos da média e uma maior amplitude entre os valores máximos e mínimos, podendo ser um reflexo do grande fator aleatório da exploração da vizinhança ao sortear um talhão, diferentemente




Figura 7. Evolução do VPL máximo para quantidade de cálculos de função objetivo.

da vizinhança sistemática, que obteve resultados mais centralizados. O *simulated annealing* resultou nos maiores VPL's e uma maior centralização dos resultados, tendo apenas um *outlier* ao explorar a vizinhança aleatória.




Figura 8. Comparação da evolução do VPL máximo dos melhores experimentos para cada algoritmo e sua vizinhança.

5. Conclusão

As abordagens apresentadas neste trabalho, de geração de vizinhança, utilizando as heurísticas de busca local, *simulated annealing* e uso de métodos de primeira e melhor melhora e Algoritmo Genético, mostraram que é possível explorar o espaço de busca de forma eficaz e encontrar soluções com boa eficiência em relação à literatura. A análise dos resultados mostrou que o uso de uma busca local nas vizinhanças aleatória e localizada obtiveram resultados inferiores, diferentemente da vizinhança sistemática, que performou melhor. Já o uso do *simulated annealing* sobressaiu em relação à busca local, que encontrou bons resultados e com uma distribuição mais concentrada dos resultados. Contudo, divergentemente da literatura (RODRIGUES et al., 2004; FERREIRA et al., 2018), o algoritmo genético obteve resultados muito inferiores aos já encontrados, ficando claro que uma revisão aprofundada dos métodos implementados se faz necessária. Com isso, fica evidente que técnicas simples, como a busca local, são capazes de obter resultados satisfatórios, porém heurísticas mais robustas podem ser necessárias para ganhos ainda mais significativos com a capacidade de escapar de máximos locais em tempo hábil, sendo promissor o estudo de soluções em um espaço de tempo mais curto e a otimização de parâmetros em trabalhos futuros.

Referências

- I. A. BARRAL. Proposta de heurística para a geração de soluções válidas para um problema de planejamento da produção florestal. Dissertação (programa de pós-graduação em modelagem computacional e sistemas), Universidade Estadual de Montes Claros - UNIMONTES, 2022.
- Paulo Henrique Batista FERREIRA, Lisandra Maria MATOS, and Adriana Leandra ASSIS. Influência dos parâmetros da metaheurística *simulated annealing* em um problema de planejamento da produção florestal. *Caderno de Ciências Agrárias*, 10(1):59–67, jul. 2018. URL <https://periodicos.ufmg.br/index.php/ccaufmg/article/view/3027>.
- F. S. HILLIER and G. J. LIEBERMAN. *Introdução à pesquisa operacional*. São Paulo: McGraw-Hill, 8ª edição edition, 2006.
- K. N. JOHNSON and H. L. SCHEURMANN. Techniques for prescribing optimal timber harvest and investment under different objectives—discussion and synthesis. *Forest Science*, 23(suppl₁) : a0001 — —z0001, 1977.
- A. A. de B. JUNIOR, G. F. da SILVA, G. W. PEREIRA, and R. MELO. Aplicações de heurísticas para a solução de um problema de planejamento florestal. In *Simpósio Brasileiro de Pesquisa Operacional*, page 2430–2241, Rio de Janeiro, 2012.
- C. A. A. JUNIOR, R. V. O. CASTRO, J. B. MENDES, and H. G. LEITE. Can linear programming assist metaheuristics in forest production planning problem? *FLORESTA*, 51(3):751–759, 2021.
- F. L. RODRIGUES, H. G. LEITE, H. N. SANTOS, and A. L. SOUZA. Solução de problemas de planejamento florestal com restrições de inteireza utilizando busca tabu. *Revista Árvore*, 27(5):701–713, 2003.
- F. L. RODRIGUES, H. G. LEITE, H. N. SANTOS, A. L. SOUZA, and G. F. SILVA. Metaheurística algoritmo genético para solução de problemas de planejamento florestal com restrições de integridade. *Revista Árvore*, 28(2):233–245, 2004.

- M. A. P. WERNEBURG. Planejamento em grandes empresas florestais no brasil. Dissertação (mestrado em ciência florestal), Universidade Federal dos Vales do Jequitinhonha e Mucuri - UFVJM, 2015. Disponível em: <https://repositorio.ufvjm.edu.br/items/0d9bc744-d85d-428e-a3de-a759ba51e5a4>. Acesso em: 20 nov. 2024.
- G. ZÄPFEL, R. BRAUNE, and M. BÖGL. *Metaheuristic Search Concepts: A Tutorial with Applications to Production and Logistics*. Springer, 2014.